YAPAY ZEKÂ UYGULAMALARI · FİNAL PROJESİ

Evrişimli Sinir Ağı (CNN) ile Görüntü Sınıflandırma Sistemi

CIFAR-10 veri seti · CNN + Transfer Öğrenme (MobileNetV2) · Streamlit arayüz

Efe Osmanhan Güdücü

Öğrenci No: 2406022075

İstanbul Beykent Üniversitesi

SUNUM AKIŞI

İçindekiler

01 Proje Özeti

02 Problem Tanımı ve Amaç

03 Neden Bu Konu Seçildi?

04 Kullanılan Teknolojiler

05 Veri Seti — CIFAR-10

06 Yöntem · Aşama 1 — Sıfırdan CNN

07 Aşama 1 — Sonuçlar

08 Aşama 1 — Sınıf Bazında Analiz

09 Yöntem · Aşama 2 — Transfer Öğrenme

10 Aşama 2 — Sonuçlar

11 Karşılaştırma · Aşama 1 vs Aşama 2

12 Tahmin Örnekleri

13 Streamlit Web Arayüzü

14 Sonuç ve Değerlendirme

01 · GENEL BAKIŞ

Proje Özeti

Dijital görüntüleri otomatik olarak sınıflandıran bir yapay zekâ sistemi geliştirildi. Sistem, derin öğrenme yöntemlerinden Evrişimli Sinir Ağı (CNN) mimarisini kullanarak CIFAR-10 veri setindeki 10 farklı nesne sınıfını tanımaktadır.

Python ve TensorFlow/Keras ile model eğitildi; kullanıcının kolayca görsel yükleyip tahmin alabilmesi için Streamlit tabanlı bir web arayüzü hazırlandı.

AŞAMA 1 — KENDI CNN

%79.5

Test doğruluğu (10.000 görsel)

AŞAMA 2 — TRANSFER ÖĞRENME

%86.6

MobileNetV2 ile +7.1 puan

TANINAN SINIF SAYISI

10

uçak, otomobil, kedi, köpek ...

Problem Tanımı ve Amaç

PROBLEM

Görüntülerin elle sınıflandırılması

Görüntülerin insan tarafından sınıflandırılması; çok sayıda görsel söz konusu olduğunda yavaş, maliyetli ve hataya açıktır.

- Otonom araçlar
- Tıbbi görüntüleme
- E-ticaret etiketleme
- Güvenlik sistemleri

AMAÇ

Otomatik ve doğru sınıflandırma

Bir görseli girdi alıp ait olduğu sınıfı yüksek doğrulukla tahmin eden, eğitilebilir ve kullanıcı dostu bir sistem geliştirmek.

- Derin öğrenme uygulamak
- Model performansını ölçmek (accuracy / precision / recall)
- Sonuçları yorumlamak
- Kullanılabilir bir arayüz sunmak

Neden Bu Konu Seçildi?

Görüntü sınıflandırma, bilgisayarla görmenin temel ve en yaygın problemlerinden biridir; günlük hayatta da sıkça karşımıza çıkar.

- Telefon galerisinde otomatik etiketleme, yüz tanıma, plaka okuma — hep aynı problem
- CNN’ler bu alanda en başarılı yöntem; derste işlenen derin öğrenme konularını gerçek bir probleme uygulamak için ideal
- CIFAR-10 standart, erişilebilir ve akademik çalışmalarda yaygın kullanılan bir kıyaslama veri seti — sonuçlar literatürle kıyaslanabilir
- Tek bir konuda hem klasik (sıfırdan CNN) hem modern (transfer öğrenme) yaklaşımı denemek mümkün — öğretici karşılaştırma sağlıyor

Kullanılan Teknolojiler

Python 3.12
Programlama dili

TensorFlow / Keras
CNN modeli ve eğitim

MobileNetV2
ImageNet üzerinde eğitilmiş transfer öğrenme modeli

NumPy
Sayısal işlemler

Matplotlib · Seaborn
Görselleştirme, eğitim grafikleri

scikit-learn
Classification report, confusion matrix

Pillow (PIL)
Görüntü işleme

Streamlit
Web tabanlı kullanıcı arayüzü

Veri Seti — CIFAR-10

CIFAR-10 (Canadian Institute For Advanced Research) — Keras üzerinden otomatik indirilen, akademik kıyaslamalarda yaygın kullanılan dengeli bir görüntü veri seti.

60.000	50.000	10.000	32 × 32	10
Toplam görsel	Eğitim seti	Test seti	Görsel boyutu (RGB)	Sınıf — dengeli

Sınıflar

uçak · otomobil · kuş · kedi · geyik · köpek · kurbağa · at · gemi · kamyon

Ön işleme: piksel değerleri [0, 1] aralığına normalize edildi; eğitimde veri artırma (yatay çevirme, döndürme, yakınlaştırma) uygulandı.

Yöntem · Aşama 1 — Sıfırdan CNN

Model Mimarisi

- Rescaling (1/255) — normalizasyon katmanı
- Conv2D(32) + BatchNorm + MaxPooling + Dropout
- Conv2D(64) + BatchNorm + MaxPooling + Dropout
- Conv2D(128) + BatchNorm + MaxPooling + Dropout
- Flatten → Dense(128) → Dropout(0.5)
- Dense(10, softmax) — sınıf olasılıkları

Eğitim Ayrıntıları

- Optimizer: Adam · Loss: Sparse Categorical Crossentropy
- Epoch: 15 · Batch boyutu: 64
- Aşırı öğrenmeyi azaltma: Dropout + Batch Normalization + veri artırma
- Callback'ler: EarlyStopping, ReduceLROnPlateau
- Toplam eğitilebilir parametre: 552.874

NEDEN CNN?

CNN, görüntülerdeki uzamsal örüntüleri (kenar, köşe, doku, şekil) otomatik olarak öğrenir.

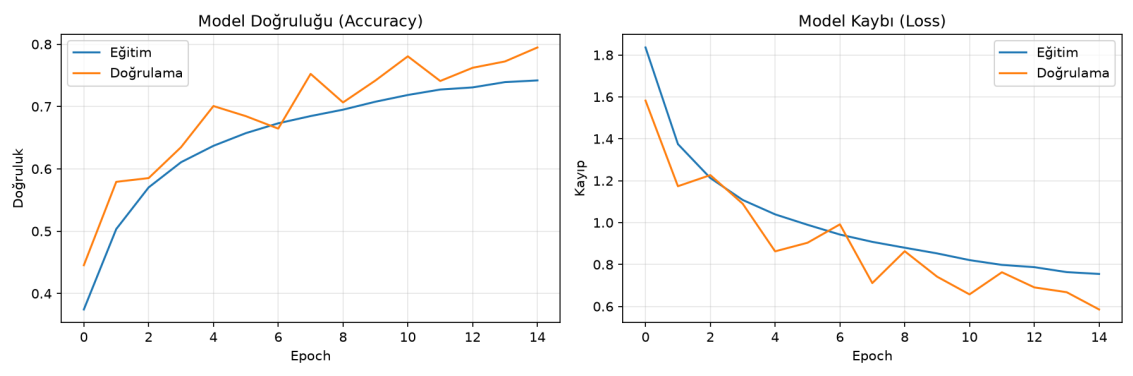
Tam bağlı (Dense) ağlara göre çok daha az parametre, çok daha güçlü genelleme.

552.874

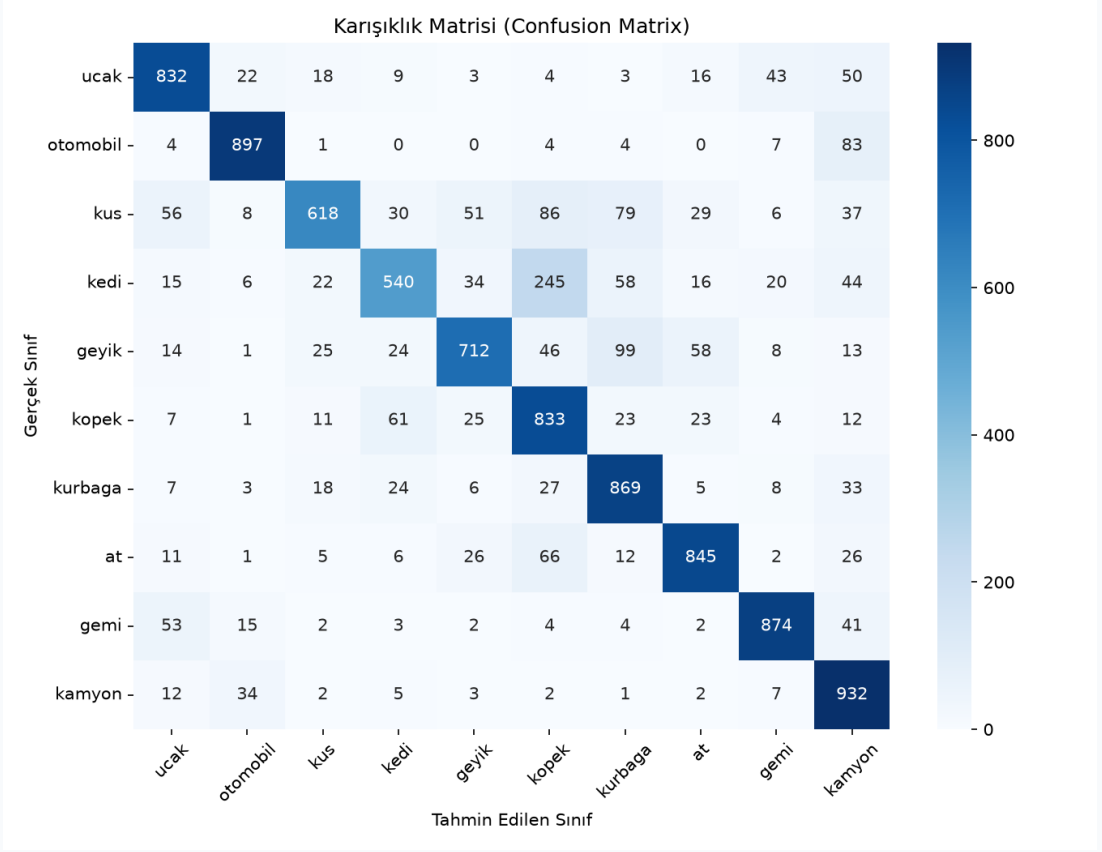
Eğitilebilir parametre

Aşama 1 — Sonuçlar

EĞİTİM EĞRİLERİ (doğruluk · kayıp)



KARMAŞIKLIK MATRİSİ



Test doğruluğu: %79.5 · Test kaybı: 0.6133

Eğitim ve doğrulama doğruluğunun yakın seyretmesi, Dropout + BatchNorm + veri artırma kombinasyonunun aşırı öğrenmeyi (overfitting) başarıyla sınırladığını göstermektedir.

Aşama 1 — Sınıf Bazında Analiz

Sınıf	Precision	Recall	F1
uçak	0.82	0.83	0.83
otomobil	0.91	0.90	0.90
kuş	0.86	0.62	0.72
kedi	**0.77**	**0.54**	**0.63**
geyik	0.83	0.71	0.76
köpek	**0.63**	**0.83**	**0.72**
kurbağa	0.75	0.87	0.81
at	0.85	0.84	0.85
gemi	0.89	0.87	0.88
kamyon	0.73	0.93	0.82

EN BAŞARILI SINIFLAR

- otomobil — F1: 0.90
- gemi — F1: 0.88
- at — F1: 0.85

EN ZORLU SINIFLAR

- kedi — Recall: 0.54
- kuş — Recall: 0.62
- köpek — Precision: 0.63

Karmaşıklık matrisi, en yoğun karışıklığın kedi ↔ köpek arasında olduğunu gösteriyor. Köpek sınıfının kesinliği (0.63) düşük: model birçok görseli hatalı şekilde "köpek" etiketliyor.

Temel nedeni: 32 × 32 piksellik düşük çözünürlükte kedi ile köpek görsel olarak çok benzer.

Yöntem · Aşama 2 — Transfer Öğrenme (MobileNetV2)

Aşama 1’deki kedi-köpek karışıklığını azaltmak için ImageNet veri seti (milyonlarca görsel) üzerinde önceden eğitilmiş MobileNetV2 modeli özellik çıkarıcı olarak kullanıldı.

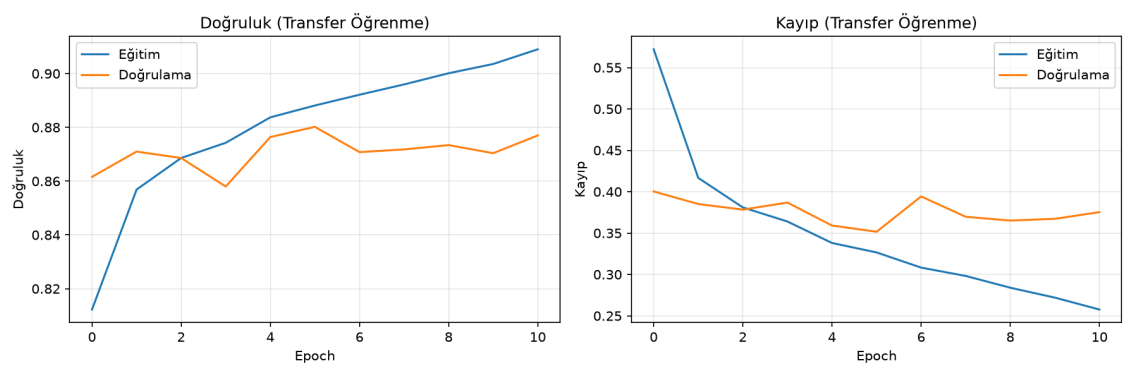


Neden bu yaklaşım işe yaradı?

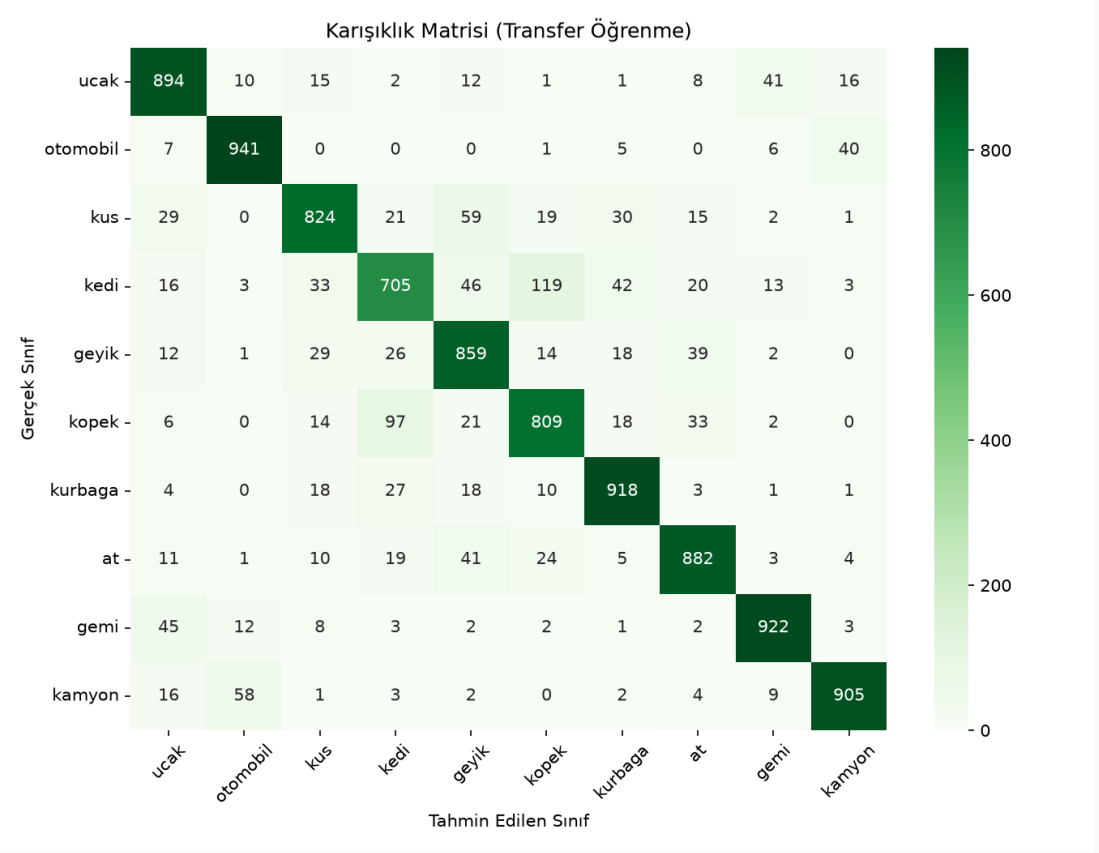
- MobileNetV2’nin öğrendiği genel görsel özellikler (doku, şekil, kenar) zaten güçlü — sıfırdan öğrenmeye gerek yok
- Özellikler tek seferde çıkarıldığı için CPU üzerinde dahi hızlı eğitim mümkün
- Doğruluk %79.5’ten %86.6’ya yükseldi; özellikle kedi-köpek karışıklığı belirgin biçimde azaldı

Aşama 2 — Sonuçlar

EĞİTİM EĞRİLERİ — TRANSFER ÖĞRENME



KARMAŞIKLIK MATRİSİ — TRANSFER ÖĞRENME



Test doğruluğu: %86.6 (Aşama 1'e göre +7.1 puan)

Karmaşıklık matrisinde kedi ↔ köpek karışıklığının belirgin biçimde azaldığı görülmektedir. Tüm sınıflarda f1-score iyileşti; en zayıf sınıf olan kedi'de iyileşme en çarpıcı oldu.

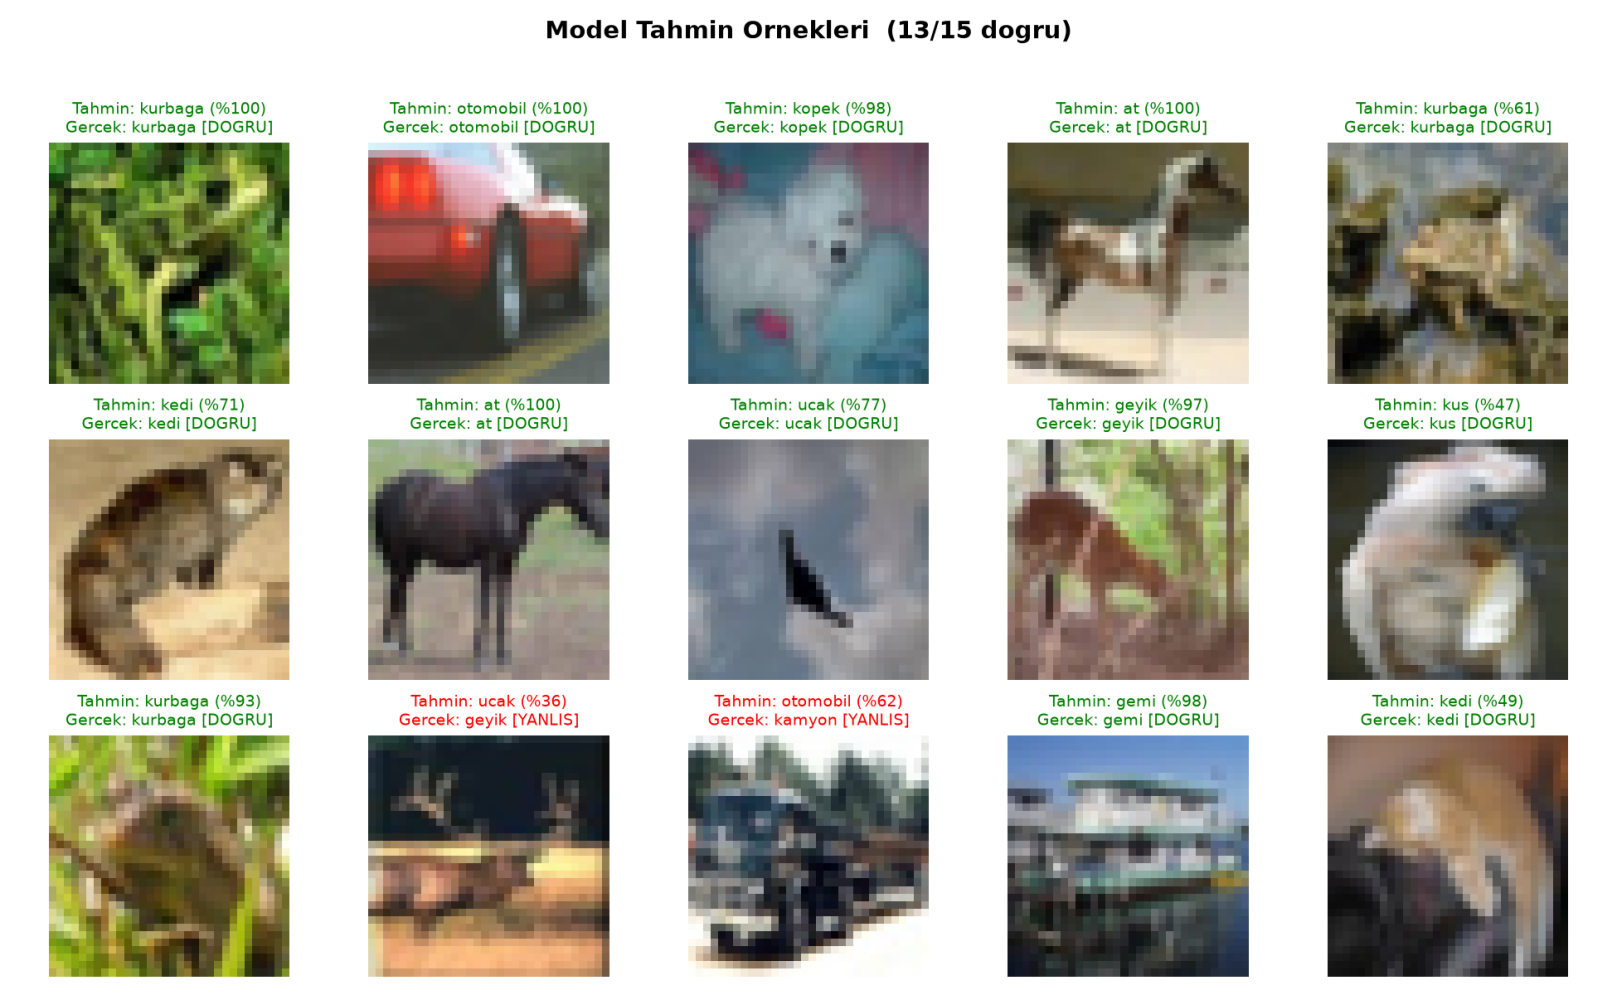
Karşılaştırma · Aşama 1 vs Aşama 2

Metrik	Aşama 1 (Kendi CNN)	Aşama 2 (Transfer Öğrenme)	Değişim
Genel doğruluk	%79.5	%86.6	**+7.1 pp**
Kedi — F1-score	0.63	0.74	**+0.11**
Kedi — Recall	0.54	0.70	**+0.16**
Köpek — F1-score	0.72	0.81	**+0.09**
Köpek — Precision	0.63	0.81	**+0.18**
Kuş — F1-score	0.72	0.84	**+0.12**

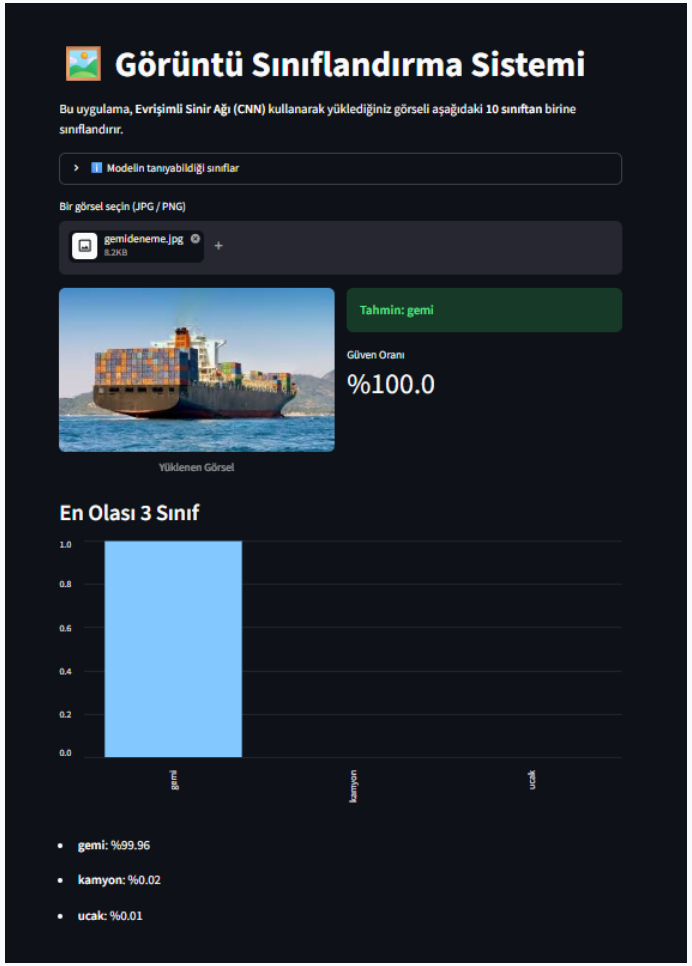
Transfer öğrenme her metrikte iyileşme sağladı; köpek precision +0.18, kedi recall +0.16.

Tahmin Örnekleri

Modelin test setinden seçilen 15 görsel üzerindeki tahminleri. Yeşil etiketler doğru, kırmızı etiketler yanlış tahmini gösterir.



Streamlit Web Arayüzü



Kullanıcı dostu, tek tıkla tahmin

- Tarayıcıdan görsel yükleme
- Eğitilmiş modelin (cifar10_cnn_model.keras) yüklenmesi
- Anlık sınıf tahmini ve olasılık çıktısı
- Hem CNN hem transfer öğrenme modelini destekler
- python -m streamlit run app.py ile çalıştırılır

TERMİNAL

```
$ streamlit run app.py
```

Sonuç ve Değerlendirme

GENEL DOĞRULUK

%86.6

İYILEŞME

+7.1 pp

KÖPEK PRECISION

+0.18

Çıkarımlar

- Sıfırdan tasarlanan CNN, yalnızca 15 epoch ile %79.5 doğruluk — görsel özellikleri başarıyla öğrendi.
- Transfer öğrenme, doğruluğu %86.6’ya çıkarırken kedi-köpek karışıklığını belirgin biçimde azalttı.
- Düşük çözünürlük (32 × 32) hâlâ temel kısıt; daha yüksek çözünürlüklü veri ile daha iyi sonuç beklenir.

Geliştirme Önerileri / Gerçek Hayatla İlişki

- Fine-tuning (MobileNetV2’nin son katmanlarının da eğitime açılması)
- Daha yüksek çözünürlüklü ve daha geniş bir veri seti kullanmak
- E-ticarette otomatik ürün kategorizasyonu, içerik filtreleme, otonom sistemlerde nesne tanıma